

prompt inject

LAWgico

Manual do Usuário

Detecção de Prompt Injection e Análise de Risco Jurídico em Peças Processuais

Peixoto & Cury Advogados · Controladoria · June de 2026

IA Claude Opus

Scan Estático + IA

v1.0

Contexto: O que é Prompt Injection?

Modelos de IA (como Claude) processam texto de documentos enviados pelo usuário.

Agentes mal-intencionados podem inserir instruções ocultas dentro de PDFs — chamadas de prompt injection.

Essas instruções tentam 'sequestrar' a IA para que ignore o contexto jurídico e execute comandos maliciosos.

Exemplo real detectado: boleto da Claro embutido numa petição trabalhista da Telefônica.

O que o sistema faz

-  Scan estático — detecta padrões suspeitos sem IA (rápido, sempre roda)
-  Análise IA (Claude Opus) — confirma ou descarta com citação obrigatória de trecho
-  Risco jurídico — nível de agressividade 1–5, verbas pedidas, teses e pontos de atenção
-  Relatório Excel — exportável para a sócia responsável

1 Acesse o sistema

lawgico-prompt-inject.streamlit.app

2 Informe o cliente

Campo opcional — ex: Telefônica, Bridgestone

3 Escolha o modo

Completo (padrão) · Só Injection · Só Risco Jurídico

4 Faça upload dos PDFs

Qualquer peça: inicial, sentença, laudo, contestação...

5 Clique Analisar

O sistema processa: scan estático → IA → resultado por documento

6 Exporte o relatório

Aba Relatório → Gerar Excel com todas as análises

Completo

Modo padrão — recomendado para todos os casos
Executa scan estático + análise IA Claude Opus
Detecta: injection + avalia risco jurídico
Resultado: score de risco, nível de agressividade,
verbas pedidas e teses identificadas

Só Prompt Injection

Foca apenas na detecção de conteúdo malicioso
Scan estático (Unicode invisível, resets, fake JSON,
conteúdo fora de contexto)
Análise IA confirma ou descarta com citação
Ideal para varredura rápida de grandes lotes

Só Análise de Risco

Analisa apenas o risco jurídico do documento
Nível de agressividade 1–5
Identifica: verbas pedidas, valor estimado,
teses jurídicas e pontos de atenção
Útil para triagem de carteira sem foco em injection

Prompt Injection — Risco

CRÍTICO	Unicode invisível em massa, fake JSON, jailbreak, marcadores de sistema
ALTO	Reset de instrução, 'ignore previous', identidade falsa
MÉDIO	Conteúdo fora de contexto (boleto, nota fiscal), caracteres suspeitos
LIMPO	Nenhuma anomalia detectada — documento processual legítimo

Agressividade Jurídica — Nível

N1	Rotineiro — pedidos conservadores, sem cálculos agressivos
N2	Moderado — alguns pedidos além do padrão
N3	Elevado — verbas agressivas, honorários altos
N4	Alto — pedidos acima de R\$500k, teses arriscadas
N5	Crítico — valor alto + teses agressivas + dano moral maximizado

O problema dos falsos positivos

PDFs do PJe contêm assinaturas digitais com hashes SHA-256 — sequências longas de caracteres alfanuméricos.

Sem whitelist, o sistema detectaria essas sequências como 'caracteres suspeitos' (falso positivo).

Resultado anterior no piloto Telefônica: 1 falso positivo por hash de assinatura digital.

Whitelist implementada — o sistema reconhece e ignora:

- ✓ 'Assinado eletronicamente' / 'Assinado digitalmente'
- ✓ SHA-256 / SHA-512 / MD5 seguidos de hash
- ✓ 'Código de verificação' (QR Code PJe)
- ✓ 'Certificado digital ICP-Brasil'
- ✓ 'PJe — Processo Judicial Eletrônico'
- ✓ 'Chave de assinatura'

Fila de Revisão Manual

Quando o scan estático e a IA discordam — ex: estático detecta ALTO mas IA classifica LIMPO — o documento vai para a fila de revisão com confiança MÉDIA. O revisor humano decide o resultado final.

Visão Geral

KPIs: total analisado, CRÍTICO, ALTO,
fila de revisão e nível 4–5
Texto para envio por Teams / e-mail
Visão consolidada de todos os documentos

Processos

Tabela com um resultado por arquivo
Filtros por risco de injection e agressividade
Detalhes: método extração, páginas, chars
Ordenado por risco decrescente

Injeções

Detalhe de cada achado de injection
Tipo, risco, confiança e trecho citado
Cards com cor por nível de risco
Somente documentos com achados

Revisar

Documentos na fila de revisão manual
Scan e IA discordaram — requer decisão humana
Botão de ação: confirmar ou descartar
Histórico de revisões da sessão

Relatório

Gerar Excel com 3 abas:

- Resumo executivo
- Todos os documentos
- Suspeitos com detalhe de achados

CRÍTICO — Confirmado

Processo: carteira Telefônica
Achado: BOM (U+FEFF) + boleto da Claro embutido na petição trabalhista

Scan estático: CRÍTICO
IA Claude: CRÍTICO — confirmado
Confiança: Alta

Trecho citado pela IA:
"código de barras: 836600000..."
"Claro S.A. — vencimento: 15/03"

→ Conteúdo completamente fora de contexto processual trabalhista

INCERTO — Fila de Revisão

Achado: sequência Log[...]
Scan: MÉDIO
IA: LIMPO (provável artefato)

→ Discordância → fila manual
→ Nova ferramenta detecta e sinaliza corretamente

FALSO POSITIVO — Corrigido

Hash SHA-256 do PJe detectado como 'caracteres suspeitos' no piloto antigo

Nova ferramenta:
→ Whitelist PJe implementada
→ Assinaturas digitais ignoradas automaticamente
→ Zero falsos positivos de PJe

prompt inject

LAWgico

Dúvidas? Fale com a Controladoria.

lawgico-prompt-inject.streamlit.app

Peixoto & Cury Advogados · June de 2026